


BÁO CÁO DỰ ÁN

XÂY DỰNG HỆ THỐNG DỮ LIỆU CUSTOMER 360

PHÂN TÍCH HÀNH VI VÀ XU HƯỚNG NGƯỜI DÙNG



Hình 1 Dashboard Customer 360 - Bức tranh toàn cảnh về mức độ tương tác và phân tán hành vi người dùng.

Công nghệ ứng dụng: Apache Spark (PySpark), Python, MySQL, SQL, Tableau

1. MỤC TIÊU DỰ ÁN (PROJECT OBJECTIVE)

Dự án được thực hiện nhằm giải quyết bài toán phân mảnh dữ liệu khách hàng. Ban đầu, dữ liệu "Tìm kiếm" (*log_search*) và "Hành vi xem thực tế" (*log_content*) được lưu trữ độc lập dưới các định dạng khác nhau (Parquet, JSON).


Mục tiêu cốt lõi là xây dựng một luồng xử lý dữ liệu (ETL Pipeline) để làm sạch, chuẩn hóa và hợp nhất hai nguồn này thành một Góc nhìn 360 độ về khách hàng (Customer 360 Data Mart), phục vụ cho việc trực quan hóa bằng Tableau và truy vấn nghiệp vụ bằng SQL.

2. KIẾN TRÚC & QUY TRÌNH XỬ LÝ DỮ LIỆU (DATA ARCHITECTURE & ETL)

Dự án được triển khai cục bộ (Local Environment) với luồng dữ liệu 4 bước rõ ràng:


1. **Extract (Trích xuất):** Đọc dữ liệu thô từ hệ thống lưu trữ file nội bộ.
 - Dataset 1: Dữ liệu tìm kiếm *log_search* (Parquet File).
 - Dataset 2: Dữ liệu hành vi xem *log_content* (JSON File).
2. **Transform (Làm sạch & Chuyển đổi):** Sử dụng sức mạnh xử lý của **Apache Spark (PySpark)** để:
 - **Luồng xử lý Dữ liệu Search (Phân tích Ý định):**
 - Lưới bắt lỗi Timestamp: Áp dụng hàm *try_to_timestamp* để parse tự động hàng loạt định dạng thời gian dị biệt từ hệ thống nguồn.
 - Thuật toán Intent Scoring: Xây dựng hệ thống chấm điểm dựa trên trọng số từ khóa (nhóm khẳng định x3.0, nhóm thể loại x2.0) kết hợp *Window Function* để lọc ra Top 5.000 Users tiềm năng nhất.
 - Auto Categorization & Human-in-the-loop: Xây dựng Rule Engine bằng *Regex* để tự động phân loại từ khóa. Các từ khóa dị biệt được xuất ra Excel xử lý tay, sau đó nạp ngược lại thành bộ từ điển Master để thực hiện Broadcast Join giúp tối ưu hiệu năng.
 - **Luồng xử lý Dữ liệu Content (Phân tích Hành vi):**
 - Bóc tách JSON & Tiền xử lý: Định nghĩa StructType *Schema* để ép kiểu chuẩn xác dữ liệu lồng ghép. Trích xuất ngày tháng từ tên file bằng *Regex*.
 - Data Mapping & Pivot: Ánh xạ mã ứng dụng (*VOD, FIMS, CHANNEL..*) thành các thể loại chuẩn (*Phim Truyện, Truyền Hình..*). Xoay trục dữ liệu (*Pivot*) để tính tổng thời lượng xem từng danh mục cho mỗi *user*.
 - Trích xuất KPI Hành vi: Tính toán Tỷ lệ hoạt động (*Active Ratio = số ngày xem / 30 ngày*), tìm kiếm thể loại xem nhiều nhất (*MostWatch*) và tổng hợp gu thưởng thức (*Taste*)
 - **Làm giàu và hợp nhất dữ liệu:**
 - Chuyển hóa dữ liệu thô thành các chỉ số hành động (Actionable Metrics) phục vụ phân tích.
 - Thực hiện JOIN hai luồng Search và Content.
3. **Load (Tải dữ liệu):** Xuất DataFrame đã hoàn thiện vào cơ sở dữ liệu **MySQL** thông qua kết nối JDBC. Bảng đích *customer_360_behavier* được cấu hình kiểu dữ liệu chuẩn và đánh Index (*user_status* và *category_t7*) để tối ưu truy vấn đọc.

4. **Serve (Phục vụ):** Kết nối **Tableau Public** trực tiếp vào **MySQL** để xây dựng Dashboard, đồng thời sử dụng **SQL** để khai thác Insight.



Hình 2 Data Architecture chuẩn Medallion - Luồng xử lý ETL tự động từ Dữ liệu thô (Bronze) đến dữ liệu phục vụ phân tích (Gold Data Mart).

Kết quả đầu ra: Mô hình Dữ liệu Customer 360



Hình 3 Lược đồ Mô hình Dữ liệu (Data Model) của Customer 360 Data Mart.

3. KẾT QUẢ PHÂN TÍCH NGHIỆP VỤ (KEY BUSINESS INSIGHTS)

Dựa trên Data Mart *customer_360_behavior* đã xây dựng, hệ thống đã trích xuất được 3 nhóm Insight quan trọng thông qua truy vấn SQL:

Insight 1: Đánh giá sức khỏe tập khách hàng (User Health & Churn)

user_status	User_Count	Average_Active_Rat...	Total_Platform_Watch_Ti...
Retained_User	4930	68.44	1886697572
New_User	69	69.23	24688706
Churned_User	1	23.33	283

Bảng 1 Phân tích Sức khỏe Người dùng - Cảnh báo rủi ro khi tỷ lệ tương tác (Active Rate) của nhóm Rời bỏ tụt dốc xuống chỉ còn 23.33%.

- Dữ liệu thực tế:** Hệ thống ghi nhận 4.930 khách hàng duy trì (*Retained*), 69 khách hàng mới (*New*) và 1 khách hàng rời bỏ (*Churned*).
- Phân tích:** Nhóm Retained đóng góp thời lượng xem khổng lồ (hơn 1.88 tỷ giây) với tỷ lệ Active trung bình là 68.44%. Đáng chú ý, khi khách hàng rơi vào trạng thái Rời bỏ (*Churned*), tỷ lệ Active của họ tụt xuống chỉ còn 23.33%.

Insight 2: Sự dịch chuyển xu hướng (Taste Shifting)

	Old_Taste_June	New_Taste_July	Shift_Volume
	K-Drama	Movies_General	298
	C-Drama	Movies_General	267
	Thai-Drama	Movies_General	100
	C-Drama	K-Drama	92
	K-Drama	Horror	78

Bảng 2 Phân tích luồng dịch chuyển sở thích (Taste) giữa tháng 6 và tháng 7, top 5 luồng dịch chuyển có số lượng cao nhất.

Content Strategy: Retention & Shift Behavior


CATEGORY:
C-Drama

RETENTION RATE:
20%

Select Category

C-Drama

Retention Rate by Category



Top 10 Transition Flow

1	K-Drama -> Movies_General	298 users
2	C-Drama -> Movies_General	267 users
3	Thai-Drama -> Movies_General	100 users
4	C-Drama -> K-Drama	92 users
5	K-Drama -> Horror	78 users
6	Anime -> Movies_General	68 users
7	K-Drama -> C-Drama	61 users
8	V-Drama -> Movies_General	60 users
9	Education -> Movies_General	59 users
10	K-Drama -> TV_Show	59 users

Scatter - Active vs Watch Time Stickiness theo Category Dashboard 1 Transition Trend KPI - Dynamic Banner KPI - Tỷ lệ giữ chân DS Top 5 DS TOP 5 ALL Dashboard 2 Sheet 18


Hình 4 Theo dõi Luồng dịch chuyển Sở thích (Taste) - Xác nhận sự chuyển dịch ồ ạt từ Phim dài tập (C-Drama/K-Drama) sang Phim chiếu rạp (Movies_General).

- **Dữ liệu thực tế:** Có một luồng dịch chuyển rất lớn của người dùng từ việc xem C-Drama (267 users) và K-Drama (298 users) trong tháng 6 sang xem Phim Truyền chung (Movies_General) trong tháng 7.
- **Phân tích:** Gu thưởng thức của tập khách hàng này thay đổi rất nhanh chỉ sau 1 tháng.
- **Đề xuất:** Đội ngũ Content cần cập nhật danh mục mua bản quyền nội dung tháng tới, ưu tiên đẩy mạnh mảng Phim Truyền (Movies_General) để đón đầu xu hướng dịch chuyển này.


Insight 3: Nhận diện nhóm Khách hàng Đa sở thích (The Explorer)

User Profiling & Engagement Analysis


Engagement by Archetype



Psychological Shift vs. Activity



The Golden Taste Combinations



Hình 5 Phân tích Chân dung Đa sở thích (The Explorer) - Nhóm siêu lợi nhuận sở hữu mức độ tương tác vượt trội (81.72%) nhờ kết hợp các Tổ hợp nội dung Vàng.

user_id	user_status	Taste	Active	Target_Watch_Ti...
99521500	Retained_User	Truyện Hình - Phim Truyện - Giải Trí - Thiếu Nhi - Thể Thao	100	505749
48422690	Retained_User	Truyện Hình - Phim Truyện - Giải Trí - Thể Thao	93.33	175864
45433759	Retained_User	Truyện Hình - Phim Truyện - Thể Thao	83.33	148845
99099225	Retained_User	Truyện Hình - Phim Truyện - Thiếu Nhi - Thể Thao	100	87836
41094115	Retained_User	Truyện Hình - Phim Truyện - Giải Trí - Thiếu Nhi - Thể Thao	100	45482
46964545	Retained_User	Truyện Hình - Phim Truyện - Thể Thao	93.33	42186
49841674	Retained_User	Truyện Hình - Phim Truyện - Giải Trí - Thể Thao	100	35135
06062896	Retained_User	Truyện Hình - Phim Truyện - Thể Thao	100	34293
98941759	Retained_User	Truyện Hình - Phim Truyện - Giải Trí - Thể Thao	100	34063
47365462	Retained_User	Truyện Hình - Phim Truyện - Giải Trí - Thiếu Nhi - Thể Thao	100	31507

Bảng 3 Truy vấn định vị Khách hàng VIP - Ứng dụng chỉ số Target_Watch_Time (Phim Truyện + Thể Thao) để tối ưu hóa tệp mục tiêu Cross-selling.

- Dữ liệu thực tế:** Hệ thống loại bỏ nhiễu dữ liệu bằng cách tạo chỉ số *Target_Watch_Time*, qua đó lọc ra Top 10 người dùng năng nổ nhất (Active > 80%) thích cả *Phim Truyện* và *Thể Thao*. Tổ hợp nội dung đắt đỏ này giúp tối ưu doanh thu (ARPU) và phá vỡ tính thời vụ (khách cày phim hàng ngày sẽ không hủy gói cước khi hết mùa giải bóng đá).

- **Đề xuất Hành động:** Bàn giao danh sách cho Telesales mời nâng cấp gói "Super Premium". Áp dụng chiến thuật "Tặng thêm đặc quyền" (xem 4K, không quảng cáo) thay vì giảm giá, nhằm tri ân khách hàng và tránh rủi ro tự giẫm chân doanh thu (Cannibalization).

4. HƯỚNG MỞ RỘNG VÀ TRIỂN KHAI CLOUD (FUTURE WORK)

Với tư duy thiết kế hệ thống tách biệt giữa Lưu trữ và Xử lý (Decoupled Architecture), dự án hoàn toàn sẵn sàng (Cloud-ready) để mở rộng lên môi trường Đám mây cấp Doanh nghiệp:

- **Storage:** Dịch chuyển thư mục Data Lake nội bộ lên Amazon S3 hoặc Azure Data Lake Storage (ADLS).
- **Compute:** Triển khai mã nguồn PySpark hiện tại lên các cụm tính toán phân tán như Amazon EMR hoặc Databricks để xử lý dữ liệu ở quy mô Terabyte/Petabyte."

5. KẾT LUẬN VÀ GIÁ TRỊ DỰ ÁN

Dự án đã chứng minh khả năng xây dựng một Data Pipeline hoàn chỉnh, đi từ việc xử lý hàng ngàn file log thô lộn xộn đến việc hình thành các bảng phân tích có cấu trúc. Không chỉ giải quyết bài toán làm sạch dữ liệu, dự án còn trực tiếp tạo ra giá trị kinh doanh bằng cách phát hiện các "nút thắt" trong hành vi người dùng, cung cấp cơ sở dữ liệu vững chắc cho đội ngũ Vận hành và Marketing đưa ra quyết định.